作业 3 · A 方向一页结论

语料 白酒 11 家 × 2026 年半年报（巨潮）｜1,531 页 / 63.9 万字 / 2,048 张表 → 4,462 块（800 字切、重合 120，每块带「公司 · 章节 · 页码」）｜**检索** 向量（Qwen3-Embedding-0.6B）∪ BM25（jieba）→ RRF，跨公司题走 fanout（11 家各 2 块 → 22 块窗口）｜**作答** deepseek-flash（temperature 0）
题目先冻结后跑：`eval/questions_a.json` SHA256 `6b218eed…`，冻结于 2026-09-24 15:00:48，之后未改过任一题。
本页数字对应 2026-10-13 的一次完整重跑（`logs/21_eval_a_run3.log`）；`outputs/eval/results_a.csv`、`outputs/A_页面截图_回答.png` 与它同源。

一、召回评价（只看检索：gold 块有没有被召回、排第几）

题型	题数	gold 进 top5	gold 进 top10	说明
单公司类（事实 3 / 细节 2 / 表格 1 / 计算 1 / 口径陷阱 1）	8	8/8	8/8	答案集中在一家公司、一张表
跨公司全景	2	0/2	0/2	gold 排到第 18、19——进了窗口但融合排序靠后
附加 · 拒答	1	—	—	无 gold，考的是肯不肯说「原文没有」

二、答案表现（只看作答：事实命中、数字核对、角标、人工判定）

题型	题数	事实命中	数字核对	人工全对	错误类型
单公司类	8	100%	8/8	8/8	—
跨公司全景	2	42%	2/2	0/2	Q9 `E3` 口径错；Q10 `E1;E6` 未召回 + 把没召回到说成原文没有
附加 · 拒答	1	—	1/1	1/1	正确拒答

计入评测 10 题：**8 题全对 / 2 题部分对 / 0 题错**（2/1/0 计分 20/22，分母含附加题）；角标 **11/11 全部合法**。

三、口径与出处核对（同一指标，合并报表 vs 母公司报表）

公司	指标	口径	出处（章节 · 页码 · 块ID）	值	题
金种子酒	营业收入	合并	第二节 p5 · `600199_2026H1_p005_t2`	236,013,679.60	Q9
金种子酒	营业收入	**母公司**	第八节 p37 · `600199_2026H1_p037_t1`	189,805,515.53	Q9
贵州茅台	归母净利润	合并	第八节 p30 · `600519_2026H1_p030_t1_3`	44,516,880,421.86	Q8
贵州茅台	净利润	母公司	第八节 p32 · `600519_2026H1_p032_t1_2`	17,062,381,326.67	Q8
贵州茅台	所有者权益合计	合并	第六节 p25 · `600519_2026H1_p025_t1_5`	262,096,352,174.36	Q6

Q9 的「相差 477.9 倍」**不是取错了数，是取对了数、认错了表**——189,805,515.53 这个量级只在母公司利润表里出现，按合并口径应约 384 倍。**数字核对只能防编造，防不住口径错**（错的数字确实来自某块原文，核对反而给它绿灯）。

四、全景按公司取证（Q10「营收同比升降」逐家证据）

公司	营业收入(元)	同比	出处	Q9	Q10
贵州茅台	90,703,260,964.48	+1.47%	二节 p5	✅	✅
五粮液	28,416,674,541.77	+20.87%	三节 p11	❌	✅
迎驾贡酒	3,415,678,280.00	+8.08%	二节 p5	❌	❌
山西汾酒	21,044,387,808.34	−12.18%	二节 p5	✅	✅
泸州老窖	10,472,224,575.78	−36.35%	三节 p13	❌	❌
洋河股份	10,540,431,576.04	−28.76%	三节 p12	❌	❌
古井贡酒	10,131,395,927.11	−27.01%	二节 p6	❌	❌
今世缘	6,435,322,896.05	−7.41%	二节 p5	❌	❌
口子窖	1,951,744,051.30	−22.89%	二节 p5	❌	❌
老白干酒	2,103,589,926.11	−15.23%	二节 p5	✅	❌
金种子酒	236,013,679.60	−51.19%	二节 p5	❌	❌

真相是**上升 3 家**（贵州茅台、五粮液、迎驾贡酒）、**下降 8 家**。Q10 只写了 2 家上升，并把另外 8 家写成「原文未给出同比数据」——这 8 家的证据块**全部都在库里**（见上表 ❌ 列），只是没进那 22 块窗口。**「没检索到」被说成了「原文没有」**。

五、结论

> 单公司题（答案集中在一家公司、一张表）向量 + BM25 已经够用：召回 8/8、答案 8/8。跨公司全景题不行——答案在十几家公司之间的共性与差异上，而碎块检索每家只放得进 2 块，于是要么漏（Q10）、要么拿错口径的数凑一个看起来对的答案（Q9）。这正是课件 P61 – P63 诊断的「每条路线都只看到其中一角」，我们只做到 fanout 这一步，属深度二加一层修补。

逐题明细 `outputs/eval/results_a.csv`；四张分表 `outputs/eval/表1_召回评价.md`、`表2_答案表现.md`、`表3_口径核对.md`、`表4_全景取证矩阵.md`（由 `scripts/25_make_a_tables.py` 生成，可复现，含每家的块ID）。
如实交代：deepseek-flash 在 temperature 0 下**措辞仍不逐字确定**——重跑与上一轮有 6 题表述不同，逐条比对后数字与结论未变；页面截图与本 csv 出自同一套系统、同一份索引、同一批冻结题，数字与结论逐条一致，个别句子表述有出入。